06

AI-Native SDLC

Semana 6 · Productividad y calidad

Universidad Nacional Mayor de San Marcos

Facultad de Ingeniería de Sistemas e Informática

Escuela de Ingeniería de Software

Curso: Tendencias en Ingeniería de Software y Gestión

Una puerta de calidad para los datos de obra

Caso académico ficticio: Constructora Andina S.A.C.

Grupo 1

Anthony Romani · Max Astuhuaman · Guillermo Calle · Pablo Mendoza

Docente: Mg. PMP Yamil Quiñones Nieto

Periodo: 2026-2 · Fecha: 26 de octubre de 2026 · Revisión v0.2

> **BORRADOR — pendiente de revisión del equipo. Peso curricular S6: 6 %, no calificación. Elaboración asistida por IA; sin aceptación humana registrada.**

La v0.1 se conserva como antecedente. Esta revisión añade evaluación técnica posterior, mediciones de rendimiento y un rediseño editorial; no reconstruye tiempos humanos pasados ni modifica S6-001.

01 / Resumen ejecutivo

El problema y la contribución

El escenario de Constructora Andina necesita reutilizar históricos para presupuestación y control. Antes de comparar obras, debe detectar datos vacíos, números inválidos, claves repetidas y relaciones incompletas. POC-02 implementa esa puerta inicial: un validador local Python de costos y metrados sintéticos, sin acceso al ERP ni cálculo de presupuestos.

La IA intervino en requisitos verificables, diseño del contrato, implementación, pruebas y documentación. El objeto de evaluación no es solo código: es la trazabilidad entre una instrucción, un artefacto generado, sus comprobaciones y la decisión humana que aún debe adoptarse. Esta es una aplicación acotada de AI-Native SDLC, no IA operacional tomando decisiones empresariales.

Evidencia	Resultado y lectura correcta
S6-001, histórico intacto	48/48 tests: 36 casos y 12 controles. Sin correcciones iniciales.
Evaluación posterior	S6-002: 0/35 bruto por dos defectos del arnés. S6-003: 35/35 con arnés corregido; mismo validador.
Rendimiento técnico	API de 35 filas: mediana 0,896 ms; CLI: 136,781 ms. Treinta repeticiones; no productividad laboral.
Decisión académica	BORRADOR; revisión del equipo y aportes individuales pendientes.

Qué puede y qué no puede concluirse

Se dispone de una capacidad ejecutable con criterios y salidas reproducibles. No se demuestra ahorro humano, superioridad frente a desarrollo manual, veracidad económica de los datos o seguridad productiva. La aceptación de casos conocidos no equivale a certificación del software.

> **Tiempo total de desarrollo asistido, revisión humana y ahorro: NO DETERMINADOS. No existe línea base manual ni cronometraje integral desde el inicio.**

Ruta de lectura: SDLC y autonomía (03–04), arquitectura y método (05–06), evidencia y resultados (07–09), riesgos, conclusiones y fuentes (10–12). Los números remiten a páginas, no a requisitos nuevos del docente.

02 / Mapa del SDLC y oportunidades de IA

El mapa describe hechos del **repositorio académico**, no observaciones del proceso empresarial. El SDLC del ERP real es NO DETERMINADO en todas las fases. Se mantienen los diagramas históricos AS-IS/TO-BE y los supuestos del Hito I v1.2; no se infieren prácticas empresariales a partir de esta PoC.



Transversal: mantenimiento, documentación y revisión de cada cambio.

Verde: actividades ejecutadas. Empresa: SDLC no determinado. Elaboración propia / IA.

Figura 1. SDLC académico: oportunidades y puertas humanas. Elaboración propia con IA, v0.2, 26/10/2026.

Fase transversal	Evidencia actual / oportunidad propuesta
Requisitos y diseño	Hito I, supuestos y ADR: IA propone criterios/alternativas; custodio y arquitecto confirman significado.
Código y pruebas	POC-02, corpus congelado y evaluaciones: generar en entorno local y comprobar salidas; no autoaprobar.
Integración y operación	Git y verificador seguro; sin workflow CI o despliegue ERP demostrado. IA puede preparar checks y procedimientos, no ejecutarlos en producción.
Mantenimiento/documentación	Contratos, logs y versiones: detectar regresiones, sintetizar evidencia y revisar cada cambio humano.

El beneficio potencial es reducir fricción al proponer artefactos; no se cuantificó esfuerzo evitado. DORA (2025) presenta la IA como amplificador de fortalezas y debilidades organizacionales: contratos y revisión siguen siendo necesarios.

03 / Autonomía supervisada

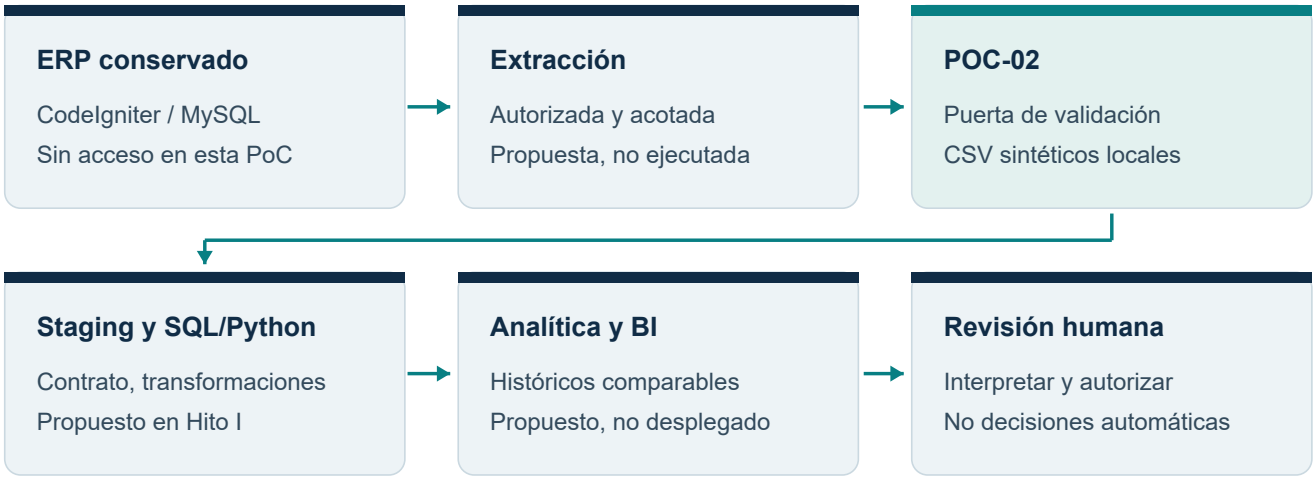
Escala académica propuesta, no estándar literal de la guía: **A0** trabajo humano; **A1** IA propone y humano decide; **A2** IA produce localmente y humano revisa/autoriza; **A3** ejecución o publicación autónoma. POC-02 aplica producción local A2 con aprobación posterior pendiente. Separar destinos no es una sandbox de seguridad ni aislamiento del evaluador.

Tarea / nivel	Riesgo principal	Control	Revisión y criterio humano
Requisitos / A1	Reglas inventadas; datos sensibles	Criterios trazables y contexto autorizado	Custodio: confirmar definiciones
Diseño / A1	Sobrediseño y acoplamiento	Mantener ERP; justificar ADR	Arquitecto: aprobar trade-offs
Código / A2	Parser plausible pero erróneo	Contrato, límites y pruebas	Técnico: leer fuente y reproducir
Pruebas / A2	Sesgo compartido y casos insuficientes	Congelar esperados y otra sesión QA	QA: contrastar contrato y discrepancias
Revisión / A1	Autocertificación por IA	Decisión separada y hallazgos	Persona: aceptar o rechazar
Seguridad / A1	Filtración o falsa garantía	Solo sintéticos; sin producción	TI/custodio: autorizar datos
Integración / A2	Sobrescribir históricos	ID exclusivo y hashes	Mantenedor: revisar diff/exit
Despliegue / A0	Interrupción del ERP	No ejecutar en esta PoC	TI: autorización y reversión
Mantenimiento / A1	Deriva de contrato/deuda	Enmiendas y regresión	Mantenedor: aprobar nueva versión
Documentación / A2	Citas o métricas falsas	Fuente original y evidencia	Equipo: comprobar y defender
Publicación / A0	Aprobar sin evidencia	Bloqueo hasta revisión real	Equipo/docente: aceptación auténtica

Los responsables son roles propuestos, no personas que ya revisaron. **A3 no se autoriza para producción, publicación final ni decisiones económicas.** Ejecutar automáticamente pruebas no sustituye la responsabilidad académica individual.

04 / Del Hito I a una puerta de calidad

Se conserva CodeIgniter/MySQL. POC-02 valida dos CSV antes de una eventual carga analítica; no extrae del ERP, escribe staging, transforma históricos ni despliega BI. La actividad se eligió por sus campos reales disponibles y resultados comprobables, sin inventar recursos o etiquetas.



Secuencia lógica: extracción → POC-02 → staging → analítica → revisión.

Solo el recuadro verde está implementado como componente local en S6.

APU futuro exige recursos, unidades, tarifas vigentes y gobierno; no se calcula aquí.

Figura 2. Ubicación conceptual de POC-02 en el TO-BE. Elaboración propia con IA, v0.2, 26/10/2026.

Decisión / deuda	Contribución S6	Lo que sigue pendiente
ADR-03 / DT-08	Python y controles reproducibles	Revisión e integración del mantenedor
ADR-04 / DT-01, DT-02	Contrato, claves y correspondencia	Unidades, monedas y comparabilidad real
ADR-06 / DT-07	Estado, diagnósticos, logs y hashes	Alertas y revisión humana empresarial

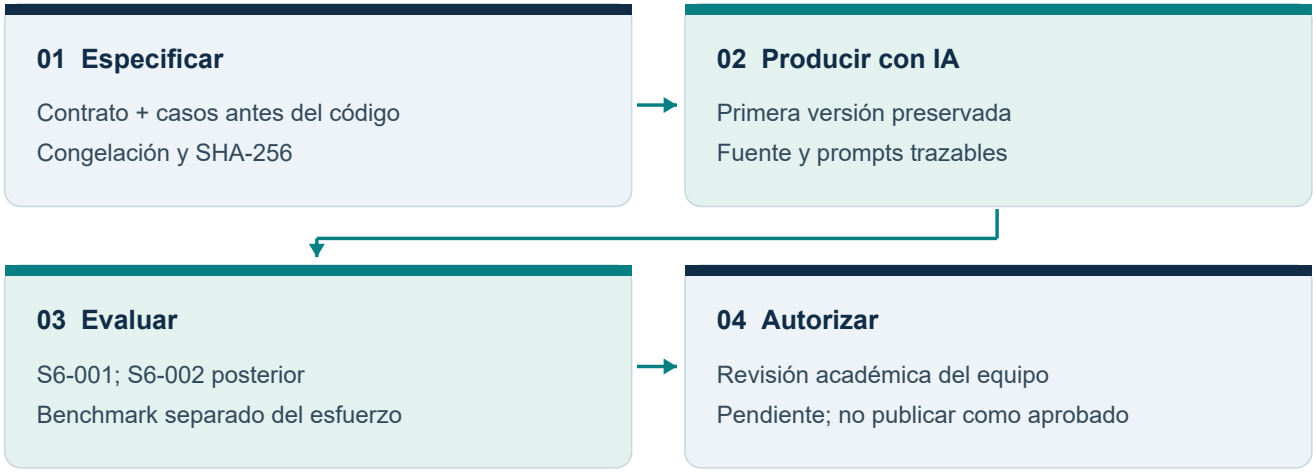
Contrato pequeño y explícito

API `validar(costos: Path, metrados: Path) -> dict`; CLI JSON: exit 0 válido, 1 inválido, 2 uso incorrecto. CSV UTF-8/BOM, columnas exactas y orden libre. IDs normalizados solo en memoria; valores Decimal ASCII finitos y positivos. Duplicados y claves sin pareja invalidan la entrada.

Límites locales: 1 MiB/archivo, 4096 caracteres/campo y 128/ID o número; sin symlinks. Fallos estructurales deshabilitan correspondencias para evitar cascadas. Mensajes ordenados, sin valores privados ni rutas. Estos son controles del contrato, no garantías de calidad económica.

05 / Desarrollo con IA y método de evaluación

Herramienta declarada: OpenCode 2.1.4; modelo GPT-6.1 Sol; Python 3.12.10. La PoC usa biblioteca estándar y no necesita IA en runtime. No se instalaron dependencias. Sampling, semilla del modelo, tokens y costo: NO DETERMINADOS. Las bibliotecas documentales solo exportan/renderizan; unittest sustenta el registro automatizado (Python Software Foundation, s. f.).



Si hay discrepancias: conservar resultado, identificar revisión y volver a evaluar.

Sesión QA distinta ≠ aislamiento material ni evaluación humana.

Figura 3. Del contrato a la autorización: evidencia antes de cada decisión. Elaboración propia con IA, v0.2, 26/10/2026.

Dos etapas, sin reescritura retrospectiva

S6-001: contrato/protocolo/casos/suite congelados antes del código; primera versión conservada; 48/48 tests. H-S6-F se limita a satisfacer ese corpus. No hubo fallos o retrabajo iniciales; no se inventa una comparación antes/después.

S6-002: evaluación técnica automatizada adicional, posterior a la implementación. Una sesión QA con contexto inicial distinto recibió contrato y corpus previo para evitar duplicaciones, con instrucción de congelar esperados antes de leer/ejecutar la fuente. Las reglas por caso justifican expectativas, no una segunda opinión humana.

La sesión comparte filesystem, proveedor/herramienta y familia de modelo. No hubo permisos de ocultación de fuente ni custodio independiente; **no es una evaluación ciega o totalmente independiente**. S6-002 se congeló antes de observar la fuente; su corrección posterior ya conoce las salidas. El benchmark es otra operación y sus repeticiones no cuentan como nuevos casos funcionales.

> **Aceptación técnica ≠ aprobación académica. Un hallazgo posterior debe conservarse y corregirse en una revisión identificada, nunca cambiando S6-001 o el contrato para favorecer la puntuación.**

06 / Evidencia visible de ejecución real

Ejemplo inválido ejecutado sobre una copia byte a byte del validador original, con exit 1. Es una demostración visual, no otro caso puntuado. Los datos de metrado contienen la misma clave y cantidad 2.5. No se simula una captura de terminal.

Entrada y comando efectivamente ejecutado

```
obra_id,partida_id,costo_real
OB-DEMO,P-01,-0.25
```

```
python -X utf8 -B validador.py --costos costos.csv --metrados metrados.csv
```

Respuesta real del CLI

```
{
  "version_contrato": "1.0",
  "estado": "INVALIDO",
  "archivos": {
    "costos": {
      "filas": 1
    },
    "metrados": {
      "filas": 1
    }
  },
  "errores": [
    {
      "archivo": "costos",
      "fila": 2,
      "campo": "costo_real",
      "codigo": "E_NO_POSITIVO",
      "mensaje": "El valor debe ser estrictamente positivo."
    }
  ]
}
```

Procedencia: `evidencias/semana-06/revision-v0.2/ejemplo-cli/`: costos.csv, comando.txt, stdout.json y registro.json. Bloques transcritos de esos archivos; solo se normalizan terminadores de línea para maquetar, sin cambiar el contenido textual.

Resumen histórico auténtico, no un resultado recreado

```
Ran 48 tests in 1.435s

OK
```

Extracto exacto de las líneas 51–53 de `poc/POC-02-ai-native-sdlc/resultados/S6-001/unittest.log`. El tiempo interno del log y el envolvente perf_counter (1,448975 s) tienen fronteras distintas.

07 / Evaluación adicional y calidad

Se ampliaron fronteras de longitud, Unicode, decimales/exponentes, duplicados combinados, CSV multilínea y tamaño exacto de archivo. S6-002 conservó **0/35 bruto por dos errores del evaluador**. Tras corregir solo el arnés y la fila esperada de A20, S6-003 obtuvo **35/35 = 100 %**, con 10 válidos y 25 inválidos. **Q2: 0/25; Q3: 0/10.** No se detectaron defectos del validador.

Cada evaluación ejecutó 109 procesos: 35 escenarios ×3 seeds, tres controles CLI exit 2 y un symlink real. En S6-003, 35/35 escenarios fueron deterministas entre seeds. Son dos corridas sobre los mismos 35 escenarios, no 70 casos nuevos. A15/A28 conservan oráculos parcialmente ambiguos; el resultado no es validación contractual absoluta.

Trazabilidad de requisitos a evidencia

Requisito	Evidencia histórica	Ampliación posterior
RF-01 Columnas	C03–04, C17–18, C31	A21–24: BOM, duplicadas y caja
RF-02 Identificadores	C08, C13–14, C36	A01–07, A19: longitud y Unicode
RF-03 Números finitos	C02, C05–07, C22–26	A08–13, A16: formato y exponentes
RF-04 Positividad	C09–12	A11–12, A14: cero y signo
RF-05 Duplicados	C15–16	A14–15, A17, A35: interacciones
RF-06 Correspondencia	C27–28, C13–14	A06–07, A16, A20: claves/filas
RF-07 Archivo/CSV	C19–21, C29–33	A25–34 y symlink real
RF-08 Determinismo	Control técnico 01	Tres seeds por escenario
RF-09 Inmutabilidad	Hashes; controles 02–03	Hashes de fuente, suite y fixtures
RF-10 Estado/CLI	36 estados; controles 08,11	Estados y CLI 0/1/2

Q1 = 100 × casos con expectativas satisfechas / casos evaluados. Q2 = inválidos aceptados / inválidos; Q3 = válidos rechazados / válidos. Los controles de CLI/determinismo/integridad se contabilizan aparte. No se suma todo bajo una tasa engañosa ni se mide cobertura de ramas por contar requisitos.

Hallazgos: EV-01 exigía contadores planos no impuestos por el contrato; EV-02 esperaba fila 5 donde el registro termina en la 4. Se realizó una iteración correctiva del arnés y cero correcciones del validador. El 0/35 inicial no son 35 falsos rechazos de datos: es fallo de la comprobación del evaluador. Dos ambigüedades (duplicados con ID inválido y código del límite de campo) siguen abiertas. Los 10 RF tienen evidencia pertinente, no cobertura exhaustiva.

08 / Rendimiento no es productividad humana

Se midieron dos cargas válidas: los originales de 35 filas/archivo y fixtures nuevos de 1000 filas/archivo. Treinta repeticiones por modo/tamaño, tras tres calentamientos; suite histórica de 48 tests repetida cinco veces tras un calentamiento. Todas las observaciones individuales se conservan. Mediana = centro ordenado; mínimo y máximo = extremos observados, sin intervalos de confianza.

Grupo	n	Mediana (ms)	Mínimo (ms)	Máximo (ms)
API · 35 filas	30	0,896	0,880	1,300
CLI · 35 filas	30	136,781	128,912	146,032
API · 1000 filas	30	10,759	10,304	26,563
CLI · 1000 filas	30	146,418	140,904	171,309
Suite · 48 tests	5	692,211	657,532	778,719

Fuente: `resultados/S6-BENCH-002/benchmark.json` y tiempos.csv, dentro de POC-02. Son 125 observaciones medidas, además de calentamientos excluidos del resumen. Unidades convertidas de segundos a milisegundos y redondeadas a tres decimales. Python 3.12.10 / Windows AMD64; parámetros y entorno íntegros en el JSON. La sesión QA había terminado antes de medir.

API: perf_counter rodea validar; incluye lectura/parser/diagnósticos, excluye importación. **CLI:** incluye arranque de intérprete, imports, lectura, JSON y captura por subprocess. La diferencia API–CLI no aísla únicamente el arranque. **Suite:** incluye fixtures, aserciones y subprocess de sus controles; no es latencia de una validación.

Orden fijo secuencial, cachés calientes y carga externa no controlada. No se fijaron afinidad ni frecuencia de CPU. La dispersión refleja este entorno Windows, no un SLA o benchmark empresarial. No debe compararse causalmente con la corrida única S6-001 ni extrapolarse a volúmenes mayores.

Dimensión	Qué significaría	Estado en esta revisión
Productividad del desarrollador	Valor/calidad obtenidos frente al esfuerzo total	NO DETERMINADO: no se cronometró todo el proceso
Esfuerzo de revisión	Intervalos reales de lectura, prueba y decisión humana	NO DETERMINADO: equipo aún no revisó
Rendimiento del software	Tiempo para ejecutar una carga definida	Medido con repeticiones; no ahorro laboral

Becker et al. (2026) discuten selección de tareas y dificultad de registrar tiempos con agentes concurrentes. Sus resultados no se transfieren a esta PoC. No hay Tmanual: no se calcula reducción relativa ni se usa cantidad de código como productividad.

09 / Riesgos, deuda y validez

AI-Native SDLC no significa sustituir todo el ciclo por generación: aquí aporta propuestas y artefactos comprobables, mientras mantiene decisiones de dominio, integración y publicación bajo control humano. La producción inicial correcta en un corpus conocido no resuelve el problema de confiar en código generado.

Riesgo	Consecuencia	Control y límite residual
Oráculo sesgado	Código y pruebas comparten supuestos	Otra sesión y reglas por caso; sin independencia material
Formato ≠ significado	Un costo positivo puede ser falso	Custodio, unidades y catálogos futuros; no se valida economía
Entradas hostiles	Carreras, enlaces o agotamiento	Límites y solo lectura; no servicio endurecido ni garantía TOCTOU
Privacidad	Exponer históricos restringidos al modelo	Solo sintéticos; mensajes sin valores; no acceso ERP
Dependencia y deuda	Equipo incapaz de mantener reglas	Contrato, tests versionados y lectura humana; IA no es fuente de verdad
Deriva documental	Confundir corridas o atribuir aportes	Hashes y nuevas rutas; no reescribir resultados/autorías

Amenazas a la validez

Interna: la segunda sesión reduce contexto compartido inmediato, no garantiza un oráculo independiente. **De constructo:** tiempo de máquina no mide esfuerzo humano; Q1 no representa valor de negocio. **Externa:** dos cargas sintéticas, un entorno/modelo y ningún ERP productivo. **Reproducibilidad:** repetir el código es posible; regenerar idéntica respuesta del modelo no está garantizado sin configuración/transcripción completas.

SSDF integra prácticas de seguridad al SDLC, no certifica una PoC por pasar tests (Souppaya et al., 2022). La deuda pendiente incluye contrato no aprobado por custodio, evaluación humana ausente, semántica incompleta e integración/operación no realizadas. Las reglas no cierran por sí solas DT-01/02/07/08 ni supuestos S-08/S-24 del Hito I.

No se midió cobertura de líneas/ramas, seguridad adversarial, valor económico, costo del modelo o esfuerzo humano. El escaneo final de patrones de secretos es acotado; no certifica su ausencia universal.

10 / Evolución, conclusiones y decisión

De validar a presupuestar por recursos

Actual: POC-02 comprueba columnas, IDs, números, claves y relaciones de dos CSV. **Propuesto en el TO-BE:** extracción autorizada, staging, históricos comparables, transformación analítica y BI bajo revisión. **Futuro:** APU que relacione mano de obra (horas-hombre, categorías, tarifas), materiales (cantidades, precios y desperdicio), equipos (horas y tarifas), metrados y rendimientos.

Con unidades, vigencia de tarifas y fuentes autorizadas, esos recursos podrían explicar costos unitarios por actividad/partida, presupuestos y desviaciones entre previsto y real. Nada de ello está calculado o integrado en S6. No se inventan materiales, trabajadores o precios. APU necesita contrato/modelo/gobierno nuevos y validaciones semánticas que esta PoC no proporciona.

Conclusiones basadas en evidencia

1. Capacidad técnica: existe un componente local reproducible que aporta una puerta de calidad a ADR-03/04/06. Los resultados históricos y posteriores deben interpretarse con sus propios corpus y limitaciones.

2. Aprendizaje del SDLC: la IA produjo especificación, implementación, pruebas y documentación; el valor defendible es la trazabilidad verificable entre esas actividades, no el volumen de código ni una mejora laboral presupuesta.

3. Supervisión: congelar esperados y separar sesiones ayuda a auditar, pero no sustituye evaluación humana o independencia material. El equipo debe comprender las reglas y aceptar/rechazar el resultado.

4. Límites: no se demostró productividad comparativa, exactitud económica, seguridad productiva ni APU. El benchmark caracteriza ejecución, no justifica despliegue.

Antes de presentar

- Reproducir en ID nuevo; revisar código, casos, métricas y fuentes.

- Leer el PDF completo y revisar DOCX en un procesador de texto.

- Registrar aportes individuales auténticos y tiempos reales de revisión.

- Emitir decisión aceptar/rechazar/condicionar y conservar sus evidencias.

> **Estado final académico: BORRADOR — PENDIENTE DE VALIDACIÓN HUMANA. Ni los tests ni el rediseño editorial constituyen aprobación.**

11 / Referencias y trazabilidad

Referencias APA 7

Becker, J., Rush, N., Cunningham, T., Rein, D., & Mahamud, K. (2026, 24 de febrero). *We are changing our developer productivity experiment design*. METR. https://metr.org/blog/2026-02-24-uplift-update/

DORA. (2025). *State of AI-assisted software development* [Página de presentación del informe 2025]. https://dora.dev/research/2025/dora-report/

Python Software Foundation. (s. f.). *unittest — Unit testing framework*. Python 3.12 documentation. Recuperado el 26 de octubre de 2026, de https://docs.python.org/3.12/library/unittest.html

Souppaya, M., Scarfone, K., & Dodson, D. (2022). *Secure Software Development Framework (SSDF) version 1.1: Recommendations for mitigating the risk of software vulnerabilities* (NIST SP 800-218). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.800-218

NIST es nivel 1 según guía p. 3; se satisfacen cuatro fuentes pertinentes y una cualificada. DORA: solo página/resumen, no lectura íntegra del informe. METR: complemento metodológico, no artículo arbitrado. Python sustenta el arnés de pruebas, no productividad. Se conserva la verificación original y se reconfirmaron NIST/DORA/METR durante esta revisión.

Anexos reproducibles del repositorio

Artefacto	Procedencia y propósito
Contrato y primera versión	POC-02; RF-01–RF-10 y prompts originales
Evaluación posterior	S6-002 y corrección/S6-003; expectativas y hallazgos
Benchmark	JSON; parámetros y tiempos individuales
Mejoras y pendientes	Registro v0.2 y revisión del equipo
Cumplimiento	Auditoría v0.2; guía p. 8 y reglas transversales

OpenCode/GPT-6.1 Sol generó código/texto/figuras y ejecutó herramientas; una sesión QA adicional produjo nuevos controles. No se atribuye programación manual ni revisión a los estudiantes. Los aportes individuales de los cuatro integrantes siguen pendientes de evidencia. Los prompts son extractos, no transcripción íntegra. No se hicieron commits/push ni se modificó v0.1, Hito I o POC-01. Hashes aportan consistencia local, no firma o aprobación.